

FIAP – Checkpoint 4
Alan de Souza Maximino da Silva
RM557088

Entrega: 13/04/2025

Local: MS Teams

Checkpoint 1 – Case iFood

Checkpoint iFood - Classificação com PyCaret

1. Resumo

Este projeto tem como objetivo aprimorar os modelos de classificação aplicados ao Case iFood, utilizando a biblioteca PyCaret com foco na métrica AUC (Área sob a Curva ROC). O trabalho foi realizado em grupo, com liberdade para realizar modificações nas variáveis, criação de novas features e ajuste dos hiperparâmetros para melhorar o desempenho nos dados de teste.

As etapas incluíram: análise exploratória, engenharia de atributos, modelagem, avaliação e interpretação dos resultados. O melhor modelo foi selecionado com base no AUC e aprimorado com `tune_model()`.

2. Carregamento e Análise Exploratória

- O dataset foi carregado com `pandas`.
- Foi realizada a análise de estrutura com `info()` e estatísticas com `describe()`.
- A verificação de valores nulos revelou colunas com valores faltantes, que foram tratadas.
- A matriz de correlação permitiu visualizar relações entre variáveis numéricas.
- Gráficos de distribuição e histograma auxiliaram na compreensão do comportamento das variáveis.

3. Engenharia de Atributos

- Foi criada a função `normalize_df()` para padronizar nomes de colunas e valores categóricos.
- A feature `client_years` foi criada a partir da data de cadastro do cliente.
- A coluna `id` foi removida por não agregar valor preditivo.
- Todo o dataset foi padronizado para garantir compatibilidade com os modelos do PyCaret.

4. Modelagem com PyCaret

- O ambiente do PyCaret foi configurado com o target `response`.
- Foram testados diversos modelos com `compare\_models()` e selecionado o melhor com base no AUC.
- O modelo foi ajustado com `tune\_model()` para otimizar hiperparâmetros.
- O desempenho foi avaliado com `plot\_model()` gerando curva ROC e matriz de confusão.
- A predição final foi feita com `predict\_model()`.

5. Análise e Interpretação dos Resultados

- O modelo ajustado obteve AUC superior ao baseline inicial.
- As transformações realizadas, como a inclusão de `client\_years` e normalização das variáveis, contribuíram para o aumento da performance.
- Os gráficos confirmam a boa separação das classes e o equilíbrio das métricas.
- O uso de técnicas como remoção de multicolinearidade e seleção de features foi fundamental.

6. Conclusão

O projeto foi concluído com sucesso, com um modelo de classificação otimizado e desempenho superior aos experimentos anteriores. O pipeline criado pode ser reutilizado em outros datasets com pequenas adaptações.

7. Entrega

Participante: Alan de Souza Maximiano da Silva

RM557088

Turma: 2TIAPY-2025

Repositório GitHub: https://github.com/alansms/CP1_Front_End_-_Mobile_Deploy

Colab: <https://colab.research.google.com/drive/12WliTJC5Xfl8KuSo8ExaGFGS7hf4Fdut#scrollTo=z6XPgbqtvF8a>